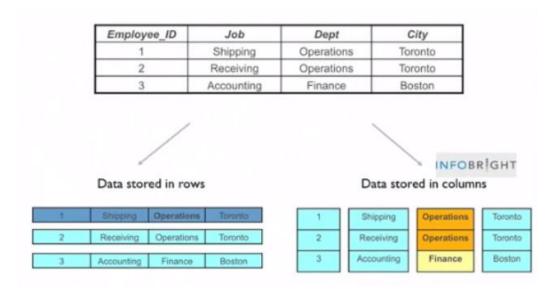
Column Block for Parallel Learning

- Data in each block is stored in the compressed column (CSC) with each column sorted by the corresponding feature value
- => Row Orientation vs Column Orientation



https://www.youtube.com/watch?v=doQfVHGfFJA 개념은 간단합니다.

보통 모든 정보를 얻기 위하여 row형태로 데이터가 저장되어있는 것을 column 기준으로 저장하는 것입니다.

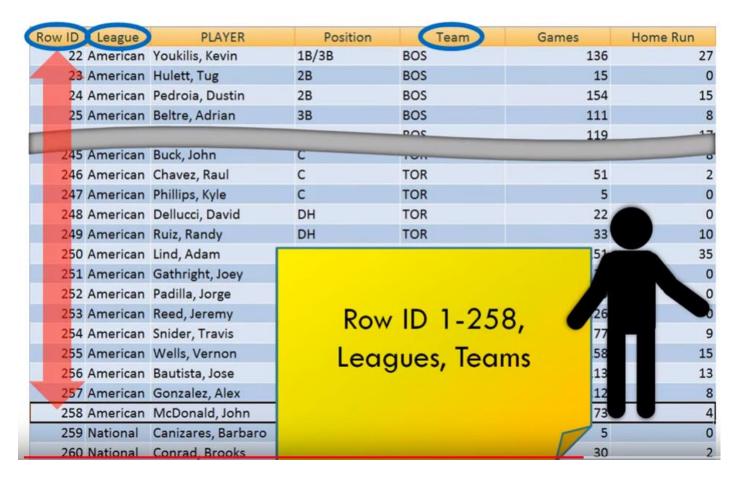


https://www.youtube.com/watch?v=8KGVFB3kVHQ

Row형태로 저장되어 있는 데이터를 특정 column에 대해 filtering이나 indexing을 하는 경우전체 데이터를 순차적으로 읽어서 각 column에 어떤 정보가 있는지 찾아야합니다.

Row ID League	PLAYER	Position		Team	Games	Home Run
1 American	Aubrey, Michael	1B	BAL		31	4
2 American	Wigginton, Ty	1B/3B/DH	BAL		122	11
3 American	Roberts, Brian	2B	BAL		159	16
4 American	Turner, Justin	3B	BAL		12	0
5 American	Atkins, Garrett	3B/1B	BAL		126	9
6 American	Moeller, Chad	С	BAL		30	2
7 American	Rodriguez, Guillermo	С	BAL		7	0
8 American	Tatum, Craig	С	BAL		26	1
9 American	Wieters, Matt	С	BAL		96	9
10 American	Scott, Luke	DH/OF	BAL		128	25
11 American	Fiorentino, Jeff	merican, American, Am	erican, A	merican, Amer	ican, America 24	0
12 American	701100) / 1010111	merican, American, Am				19
13 American	Markakis Nick	merican, American, Am merican, American, Am				18
14 American		American, Americ				
15 American	rie, relix	merican, American, Am			101	9
16 American	Paimald Malan	merican, American, Am merican, American, Am			104	15
17 American	Andino, Robert A	merican, American, Am	erican, A	American, Amer	ican, American, 78	2
18 American	izturis Cesar	merican, American, Am merican, American, Am			114	2
19 American	The state of the s	merican, American, Am		Contract of the contract of		14
20 American	Dalley, Jell	merican, American, Am		The state of the s	, , 20	3
21 American	Rates Aaron A	merican, American, Am	encan, A	American, Amer	ican, Amer 5	0

Column을 기준으로 읽게 되면 비교할 대상만 순차적으로 읽기에 filtering 등에 용이하게 됩니다.



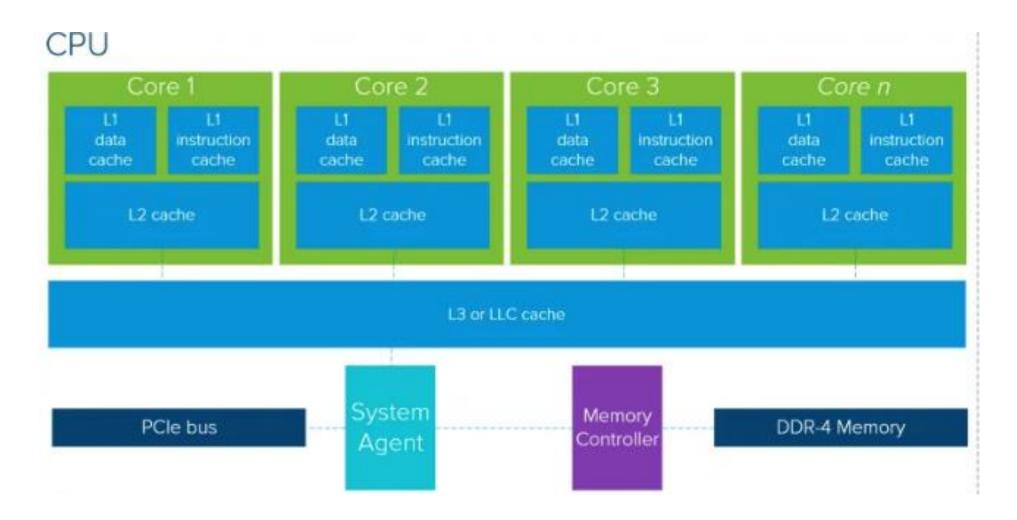
특히 sparse matrix나 컬럼이 class를 나타내는 경우는 동일한 값이 반복되어 단순하게 압축을 할 수 있는 장점이 있습니다.

우리는 Split을 할 때 column 형태의 데이터를 사용하게 되므로 기존 row형태의 데이터 저장보다 column형태로 데이터를 저장하는 경우 더 빠른 속도를 얻을 수 있습니다.

데이터를 저장하고 검색하는 것을 빠르게 할 수도 있고 대용량의 데이터가 있는 경우 column을 기준으로 정렬하여 block에 넣어놓는 다면 split이후에도 한번에 봐야할 데이터는 하나의 block에 있게 되어 Block을 읽는 I/O도 줄일 수 있습니다.

Cache-aware access

- For the exact greedy algorithm, we can alleviate the problem by a cache-aware prefetching algorithm
- I/O Speed : Cpu cache > memory > disk
 - 데이터의 접근 속도는 CPU Cache가 가장 빠르기에 최대한 오랫동안 cache의 내용을 활용하도록 만든다면 performance를 올릴 수 있습니다.
- 데이터를 저장할 때 Block 단위로 저장하고 split된 내용은 block 안에서 다시 읽게 만듭니다.



https://nielshagoort.com/2019/03/12/exploring-the-gpu-architecture/

CPU의 cache는 core와 가장 가까이 붙어있는 L1 cache부터 L3 cache까지 존재하고 Memory Controller를 사용하여 접근할 수 있는 DDR-x Memory가 그 다음으로 빠르며 SSD라고 하더라도 Disk는 이보다 훨씬 느린 속도로 접근을 합니다.

- CPU의 Cache에 데이터가 잘 저장되고 금방 재사용하도록 알고 리즘을 만든다면 오버헤드 없이 빠른 처리가 가능합니다.
- cache aware access란 cache에 어떤 데이터가 들어있는지 잘 알고 있으며 이를 다시 재활용할 수 있도록 알고리즘을 작성하는 것을 의미합니다.

Blocks for out-of-core computation

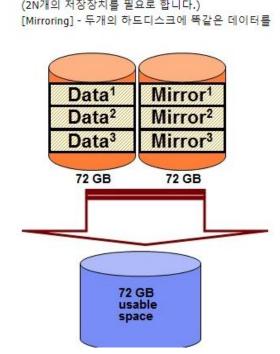
Block Compression

- Block형태로 데이터를 나누어 저장하고 column orientation으로 되어 있는 데이터를 압축하여 저장하는 것입니다. 대략 2^16개의 데이터를 하나의 block에 넣는 경우 26%~29%의 압축 효과를 볼 수 있었습니다.
- 또 하나의 key point는 읽어가면서 압축을 푸는 것입니다.
- 압축을 풀어서 저장을 하는 경우보다 적게 데이터를 읽어가면서 (요즘은 CPU가 빠르기에) 읽어가면서 압축을 풀어서 CPU내에서 연산을 할 때에는 압축이 풀린 상태로 사용하게 하는 것입니다.
- 최근 Disk의 속도가 상대적으로 느린 것을 보완하기 위하여 disk에는 압축을 하고 읽어갈 때 (on-the-fly) 압축을 풀어서 읽는 스토리지도 저장방식도 많이 있습니다.
- CPU를 조금 더 사용하기는 하지만 disk I/O가 훨씬 더 overhead가 크기에 충분히 의미가 있습니다.

Blocks for out-of-core computation

- Block Sharding
 - Disk가 여러 개 있는 경우 여러 개의 Disk에 Block 데이터를 나누어 놓습니다.
 - 데이터를 읽어올 때에는 여러 Disk를 동시에 활용하여 읽을 수 있고 Disk I/O가 느린 것을 병렬처리를 통하여 극복하는 방법입니다.
 - 우측의 그림은 RAID라는 기술입니다. 나누어 놓는 기술은 아니지만 여러 디스크를 활용하는 것에 대한 장점을 볼 수 있습니다.

왼쪽 디스크에서만 1Gigabyte의 데이터를 읽어오는 것에 비하여 두개의 디스크를 동시에 활용하여 총 500Mbyte씩 총 1Gigabyte의 데이터를 읽어오게 만든다면 물리적 장치의 속도를 두배 향상시키는 효과를 얻을 수 있습니다.



RAID 1

https://soul0.tistory.com/23